

UNIVERSIDAD DE LAS FUERZAS ARMADAS ESPE

TECNOLOGÍAS DE LA INFORMACIÓN



UNIDAD 2

INFORME DE CASO DE ESTUDIO

Predicción de Insuficiencia Cardíaca mediante Machine Learning

NRC: 30758

MATERIA: Inteligencia Artificial

DOCENTE: Ing. Mauricio Loachamin

ESTUDIANTES: Nicole Carvajal, Melanie Reimundo, Miguel Sangucho

FECHA: 24/06/2026

PREGRADO SI ABRIL 2026 – AGOSTO 2026

1. Introducción

Las enfermedades cardiovasculares (ECV) constituyen la principal causa de muerte a escala mundial, cobrando aproximadamente 17,9 millones de vidas cada año, lo que representa el 31 % del total de fallecimientos globales. Cuatro de cada cinco muertes por ECV se deben a infartos de miocardio y accidentes cerebrovasculares, y un tercio de dichas muertes ocurren prematuramente en personas menores de 70 años.

La insuficiencia cardíaca es una de las complicaciones más frecuentes y letales derivadas de las ECV. La detección temprana y el tratamiento oportuno resultan esenciales para mejorar el pronóstico de los pacientes, especialmente en aquellos que presentan factores de riesgo como hipertensión, diabetes o hiperlipidemia. En este contexto, el aprendizaje automático (machine learning) ofrece una herramienta poderosa para identificar patrones clínicos que permitan predecir el riesgo de padecer cardiopatías, complementando el juicio clínico tradicional.

El presente informe documenta el desarrollo, análisis y comparación de dos pipelines de machine learning diseñados para predecir la insuficiencia cardíaca a partir del dataset «Heart Failure Prediction Dataset» (918 registros, 11 variables predictoras). Uno de los pipelines fue generado con asistencia del modelo de inteligencia artificial Claude (Anthropic) y el otro con Gemini (Google), con el objetivo de evaluar el nivel de rigurosidad metodológica, la calidad del análisis y la certeza de los resultados obtenidos por cada propuesta.

2. Objetivos

2.1 Objetivo General

Comparar dos pipelines de machine learning —elaborados con apoyo de Claude y Gemini respectivamente— para la predicción de insuficiencia cardíaca, evaluando la solidez metodológica, la completitud del análisis y la certeza de los resultados obtenidos.

2.2 Objetivos Específicos

- Describir el dataset utilizado y las características clínicas consideradas como predictores de cardiopatía.
- Documentar las decisiones metodológicas adoptadas en cada pipeline (preprocesamiento, selección de modelos, evaluación).
- Analizar comparativamente las métricas de rendimiento obtenidas por ambos enfoques.
- Identificar cuál de los dos pipelines presentó mayor rigor metodológico y resultados más confiables.
- Formular conclusiones y recomendaciones para el uso de IA asistida en tareas de ciencia de datos clínica.

3. Metodología

3.1 Dataset

El estudio emplea el «Heart Failure Prediction Dataset», compuesto por 918 registros de pacientes y 12 columnas: 11 variables predictoras y 1 variable objetivo (HeartDisease). El dataset no presenta valores nulos, lo que facilita el preprocesamiento. Las variables incluidas son:

Variable	Tipo	Descripción
Age	Numérica	Edad del paciente en años
Sex	Categórica	Género: M (Masculino) / F (Femenino)
ChestPainType	Categórica	Tipo de dolor torácico: TA, ATA, NAP, ASY
RestingBP	Numérica	Presión arterial en reposo (mm Hg)
Cholesterol	Numérica	Colesterol sérico (mm/dl)
FastingBS	Binaria	Glucemia en ayunas > 120 mg/dl (1: Sí, 0: No)
RestingECG	Categórica	Resultados del ECG en reposo: Normal, ST, LVH
MaxHR	Numérica	Frecuencia cardíaca máxima alcanzada (60-202)
ExerciseAngina	Categórica	Angina inducida por ejercicio: S / N
Oldpeak	Numérica	Depresión del segmento ST inducida por ejercicio
ST_Slope	Categórica	Pendiente del segmento ST: Up, Flat, Down
HeartDisease	Binaria ★	Variable objetivo: 1 = Cardiopatía, 0 = Normal

3.2 Herramientas y Entorno

- Lenguaje de programación: Python 3.x sobre Google Colab.
- Librerías principales: pandas, numpy, matplotlib, seaborn, scikit-learn.
- Modelos probados: Random Forest Classifier y Regresión Logística (solo pipeline Claude).
- Pipeline Claude: generado con el asistente Claude (Anthropic), NRC 30758.
- Pipeline Gemini: generado con el asistente Gemini (Google), NRC 30758.

3.3 Esquema de Evaluación Comparativa

La comparación entre ambos pipelines se realizó sobre seis dimensiones: (1) amplitud del análisis exploratorio, (2) estrategia de preprocesamiento y codificación de variables, (3) diversidad de modelos entrenados, (4) estrategia de división train/test, (5) validación adicional mediante cross-validation, y (6) capacidad de generalización a nuevos pacientes.

4. Desarrollo

4.1 Pipeline generado con Claude

El notebook Caso2_InsuficienciaCardiaca_Pipeline.ipynb, elaborado con asistencia de Claude, presenta un pipeline de ocho etapas secuenciales y bien documentadas, desde la carga de datos hasta la predicción sobre nuevos casos de pacientes hipotéticos.

4.1.1 Análisis Exploratorio de Datos (EDA)

El EDA es extenso y estructurado. Incluye: (a) visualización de la distribución de la variable objetivo mediante gráfico de barras y diagrama de torta; (b) histogramas con estimación de densidad KDE para las cinco variables numéricas, segmentadas por clase; (c) gráficos de barras cruzadas para las cinco variables categóricas versus el diagnóstico; y (d) mapa de calor de correlación para las variables numéricas. Esta amplitud permite identificar los factores de riesgo visualmente antes de cualquier modelado.

4.1.2 Preprocesamiento

Las variables categóricas (Sex, ChestPainType, RestingECG, ExerciseAngina, ST_Slope) se codificaron mediante LabelEncoder, asignando enteros ordenados alfabéticamente a cada categoría. La división entrenamiento/prueba fue 80/20 con estratificación (stratify=y), garantizando la proporción de clases en ambos subconjuntos. La normalización con StandardScaler se aplicó exclusivamente al conjunto de datos destinado a la Regresión Logística, respetando el comportamiento del Random Forest frente al escalado.

4.1.3 Modelos Entrenados

Se entrenaron dos clasificadores: Random Forest (100 árboles, random_state=42) y Regresión Logística (max_iter=1000, random_state=42). Esto permite contrastar un modelo de conjunto basado en árboles de decisión con un modelo lineal, ofreciendo perspectivas complementarias sobre los datos.

4.1.4 Evaluación y Resultados

La evaluación incluyó accuracy, precision, recall y F1-Score para ambos modelos, acompañadas de matrices de confusión y un gráfico comparativo de métricas. El pipeline también implementa validación cruzada 5-Fold sobre todo el dataset, fortaleciendo la confiabilidad de los resultados. Los resultados documentados son:

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	~88.0 %	~88.5 %	~90.0 %	~89.2 %
Regresión Logística	~85.3 %	~85.8 %	~87.1 %	~86.4 %
CV 5-Fold RF (media)	~87.5 ± 1.5 %	—	—	—

Nota: valores aproximados según el resumen documentado en el notebook. La variación exacta depende de la semilla aleatoria y la versión de scikit-learn.

4.1.5 Importancia de Variables y Predicción en Nuevos Pacientes

El pipeline identifica ST_Slope, Oldpeak, Cholesterol, MaxHR y ExerciseAngina como los cinco factores de mayor importancia relativa según el Random Forest. Adicionalmente, incluye una etapa de predicción sobre tres casos de pacientes hipotéticos con perfiles de riesgo diferenciados, reportando la clase predicha y la probabilidad asociada, lo que aporta valor clínico al análisis.

4.2 Pipeline generado con Gemini

El notebook Analisis_Insuficiencia_Cardiaca.ipynb, elaborado con asistencia de Gemini, propone un pipeline de seis secciones más conciso, centrado en un único modelo de clasificación y con un análisis exploratorio de menor profundidad.

4.2.1 Análisis Exploratorio de Datos (EDA)

El EDA se limita a mostrar las primeras filas del dataset, la información de tipos y valores nulos, y la distribución de la variable objetivo mediante un countplot. No incluye análisis de variables numéricas por clase, variables categóricas cruzadas ni mapa de correlación, lo que reduce la capacidad interpretativa del pipeline.

4.2.2 Preprocesamiento

Las variables categóricas se codificaron mediante One-Hot Encoding (OHE) con `pd.get_dummies()` y `drop_first=True`, lo que evita la asunción de ordinalidad entre categorías nominales (enfoque teóricamente más apropiado para variables como ChestPainType o ST_Slope). Sin embargo, la división entrenamiento/prueba no utiliza estratificación, lo que puede generar desequilibrio de clases en los subconjuntos. Además, el StandardScaler se aplicó a todas las variables, incluido el Random Forest, operación innecesaria para este tipo de modelo pero que no afecta negativamente su rendimiento.

4.2.3 Modelo Entrenado y Evaluación

Se entrenó únicamente un Random Forest (100 árboles, `random_state=42`). La evaluación incluye accuracy, classification report y matriz de confusión. No se implementa validación cruzada ni comparación con otros modelos. El notebook concluye con un gráfico de importancia de características que a diferencia del pipeline Claude incluye las variables expandidas por OHE, como ChestPainType_NAP o ST_Slope_Up, ofreciendo granularidad extra sobre qué categorías específicas son más determinantes.

4.3 Comparativa entre ambos Pipelines

A continuación se presenta una tabla de comparación estructurada de las decisiones metodológicas y características de cada pipeline:

Dimensión	 Claude (Pipeline A)	 Gemini (Pipeline B)
EDA	Extenso: distribuciones, categóricas cruzadas, mapa de correlación	Básico: solo distribución de la variable objetivo
Codificación	LabelEncoder (ordinal implícita)	One-Hot Encoding (drop_first=True) — más apropiado para variables nominales
División Train/Test	80/20 con stratify=y (balanceo garantizado)	80/20 sin estratificación
Escalado	StandardScaler únicamente para Regresión Logística	StandardScaler aplicado también al Random Forest
Nº de modelos	2: Random Forest + Regresión Logística	1: Random Forest
Métricas reportadas	Accuracy, Precision, Recall, F1-Score + gráfico comparativo	Accuracy + Classification Report (sin gráfico comparativo)
Validación cruzada	Sí — 5-Fold Cross-Validation	No
Importancia variables	Sí, sobre columnas originales codificadas	Sí, sobre columnas expandidas por OHE
Predicción nuevos casos	Sí — 3 pacientes hipotéticos con probabilidades	No
Documentación	Comentarios detallados por etapa y tabla resumen del pipeline	Comentarios mínimos
Accuracy (RF)	~88.0 % (conjunto de prueba)	Similar (~87–89 %, estimado por mismo modelo y semilla)
CV 5-Fold (RF)	~87.5 ± 1.5 %	No aplicado

5. Conclusiones

Del análisis comparativo entre los dos pipelines desarrollados se derivan las siguientes conclusiones:

5.1 Sobre la rigurosidad metodológica

El pipeline generado con Claude demostró un nivel metodológico notablemente superior. La inclusión de validación cruzada 5-Fold, la estratificación en la división entrenamiento/prueba y el entrenamiento de dos modelos con diferentes supuestos (conjunto vs. lineal) brindan una estimación más robusta y generalizable del rendimiento del clasificador. La validación cruzada, en particular, es fundamental para detectar sobreajuste y obtener estimaciones de rendimiento con intervalos de confianza, aspecto que el pipeline de Gemini omitió por completo.

5.2 Sobre la codificación de variables categóricas

En este punto, el pipeline de Gemini adoptó una decisión teóricamente más adecuada al emplear One-Hot Encoding para variables nominales, evitando la imposición de relaciones de orden entre categorías como ChestPainType (ASY, ATA, NAP, TA). El LabelEncoder utilizado por Claude asigna enteros ordenados alfabéticamente, lo que puede introducir sesgo en modelos sensibles a la escala. No obstante, el Random Forest es relativamente insensible a este efecto, por lo que el impacto práctico sobre la precisión final resulta marginal en este caso.

5.3 Sobre la certeza de los resultados

Ambos pipelines emplean el mismo algoritmo base (Random Forest con `n_estimators=100` y `random_state=42`), por lo que sus accuracies sobre el conjunto de prueba son comparables ($\sim 87\text{--}89\%$). Sin embargo, el pipeline Claude es significativamente más certero en sus resultados por las siguientes razones: (a) reporta métricas completas —accuracy, precision, recall y F1-Score— para ambos modelos, lo que ofrece una visión más honesta del rendimiento, especialmente relevante en contextos médicos donde los falsos negativos tienen consecuencias críticas; (b) la validación cruzada confirma que el $\sim 88\%$ de accuracy no es un artefacto de la partición específica de los datos; y (c) la predicción sobre nuevos pacientes con probabilidades asociadas aporta utilidad práctica al modelo.

5.4 Conclusión General

El pipeline generado con Claude resultó más certero, completo y metodológicamente riguroso. Su superioridad no reside exclusivamente en las métricas numéricas —que son comparables dado el uso del mismo algoritmo y semilla— sino en la confiabilidad del proceso analítico: EDA exhaustivo, validación cruzada, estratificación, múltiples modelos y predicción aplicada. El pipeline de Gemini, aunque funcional y con una ventaja en la estrategia de codificación de variables nominales, presenta un análisis más superficial que limita la interpretabilidad y la confianza en sus resultados.

En aplicaciones de machine learning clínico, donde las decisiones tienen impacto directo en la salud de los pacientes, la rigurosidad metodológica no es opcional. En ese sentido, el pipeline A (Claude) representa un estándar más adecuado para reportar resultados científicos confiables.

5.5 Recomendaciones

- Combinar lo mejor de ambos enfoques: usar One-Hot Encoding (Gemini) junto con validación cruzada, estratificación y múltiples modelos (Claude).
- Incorporar ajuste de hiperparámetros (GridSearchCV o RandomizedSearchCV) para mejorar el rendimiento más allá del $\sim 88\%$ de accuracy basal.
- En contextos médicos, priorizar el recall sobre la precision para minimizar falsos negativos (pacientes enfermos clasificados como sanos).

- Ampliar el EDA con pruebas estadísticas (chi-cuadrado para categóricas, t-test o Mann-Whitney para numéricas) para validar la relevancia de cada variable predictora.
- Explorar modelos adicionales como XGBoost, SVM o redes neuronales para establecer un límite superior de rendimiento en este dataset.